



REPUBLIQUE TUNISIENNE
Ministère de l'Enseignement Supérieur et de la
Recherche Scientifique Université de Carthage
**Institut National des Sciences Appliquées et de
Technologies**



Projet Réalité mixte et vision 3D :
SpaceAnimal — Estimation de Pose et
Classification Comportementale de C. elegans

Spécialité : Réseaux informatiques et Télécommunications

Enseignante :
Mme Dorsaf Sbei

Elaboré par :
Ayeb Farah
Ben Amor Hanine
Melki Meriem

RT4/1

Année Universitaire : 2025/2026

Table des Matières

Table des Matières	2
1. Introduction et Contexte du Projet	3
1.1 L'Organisme Modèle : C. elegans	3
1.2 Architecture Globale du Pipeline	3
2. Datasets Utilisés	4
2.1 Dataset SpaceAnimal — Estimation de Pose	4
2.1.1 Structure et Format des Annotations	4
2.2 Dataset LabGym — Classification Comportementale	4
2.2.1 Features Biologiques Extraites	5
3. Notebook 1 — Fine-tuning YOLOv8 Pose Estimation	6
3.1 Architecture du Modèle	6
3.2 Résultats d'Entraînement — Courbes de Loss	6
3.3 Métriques de Performance	7
3.3.1 Précision et Rappel	7
3.3.2 Évolution des métriques mAP au cours de l'entraînement	7
3.4 Résultats sur C. elegans :	8
4. Notebook 2 — Classification Comportementale	9
4.1 Pipeline d'Extraction de Features	9
4.2 Classifieur 1 : Random Forest	9
4.3 Classifieur 2 : Gradient Boosting	9
4.4 Classifieur 3 : LSTM	9
4.5 Cross-Validation et Comparaison des Modèles	10
4.6 Visualisation des Distributions de Features	10
4.7 Artefacts Exportés	10
5. Notebook 3 — Pipeline d'Inférence Bout-en-Bout	11
5.1 Architecture du Pipeline d'Inférence	11
5.2 Visualisations Produites	12
5.2.1 Grille de Frames avec Keypoints	12
5.2.2 Résumé : Probabilités et Trajectoire	12

1. Introduction et Contexte du Projet

L'objectif principal est de développer un pipeline complet permettant l'estimation de pose et la classification comportementale automatique de l'organisme modèle *C. elegans* à partir de vidéos microscopes.

Objectifs du Projet

- 1) Fine-tuner YOLOv8-pose sur le dataset SpaceAnimal (*C. elegans*) pour estimer les keypoints corporels.
- 2) Extraire des features biologiques et entraîner des classifieurs (RF, GB, LSTM) pour identifier les comportements locomoteurs.
- 3) Assembler un pipeline d'inférence bout-en-bout : entrée vidéo → pose → comportement prédit.

1.1 L'Organisme Modèle : *C. elegans*

Caenorhabditis elegans est un nématode transparent d'environ 1 mm, largement utilisé en biologie comme organisme modèle. Sa simplicité anatomique (302 neurones, 95 muscles) et son comportement locomoteur bien documenté en font un candidat idéal pour développer des outils d'analyse comportementale automatisée.

Comportements étudiés : Le dataset LabGym couvre différents modes locomoteurs incluant la marche avant (forward), la marche arrière (backward), les arrêts (pause), les virages (turn) et d'autres comportements spécifiques.

1.2 Architecture Globale du Pipeline

Le pipeline complet suit une architecture en trois étapes séquentielles :

- ❖ Notebook 1 : Fine-tuning de YOLOv8s-pose sur le dataset SpaceAnimal (format COCO → YOLO), entraînement 50 époques sur GPU
- ❖ Notebook 2 : Extraction de features biologiques via le modèle entraîné, entraînement et comparaison de trois classifieurs (RF, GB, LSTM) sur le dataset LabGym
- ❖ Notebook 3 : Pipeline d'inférence complet — lecture vidéo .avi → détection de pose → extraction de features → prédiction comportementale

2. Datasets Utilisés

2.1 Dataset SpaceAnimal — Estimation de Pose

Le dataset SpaceAnimal est un dataset multi-espèces structuré pour l'estimation de pose d'animaux en microscopie. Il contient des annotations au format COCO avec keypoints pour trois espèces biologiques distinctes.

Espèce	Description	Keypoints	
C. elegans	Nématode transparent (~1 mm)	Corps entier (multiple)	6996 images
Drosophila	Mouche du vinaigre	Membres + tête	410 images
Zebrafish	Poisson zèbre larvaire	Colonne vertébrale	560 images

Choix de C. elegans : Parmi les trois espèces disponibles, *C. elegans* a été sélectionné principalement en raison de la taille plus importante de son sous-ensemble dans le dataset SpaceAnimal, ce qui favorise un meilleur apprentissage du modèle.

De plus, la disponibilité d'un dataset comportemental dédié (LabGym) permet d'établir un lien direct entre estimation de pose et classification comportementale.

2.1.1 Structure et Format des Annotations

Une conversion du dataset COCO vers le format YOLO-pose a été réalisée afin de rendre les annotations compatibles avec le modèle YOLOv8.

Cette étape inclut :

- ❖ la normalisation des bounding boxes (format center-based)
- ❖ la normalisation des keypoints
- ❖ la conversion des identifiants de classe

2.2 Dataset LabGym — Classification Comportementale

Le dataset LabGym est un dataset de clips vidéo annotés (.avi) pour la classification comportementale de *C. elegans*. Il est utilisé dans le Notebook 2 pour entraîner les classifieurs comportementaux.

Caractéristique	Détail
Format	Clips vidéo .avi annotés par classe
Organisation	Un dossier par classe comportementale
Features extraites	speed_mean, speed_std, speed_max, curvature_mean, curvature_std, elongation_mean, elongation_std, length_mean, linearity, detection_rate
Modèle utilisé	YOLOv8s-pose entraîné dans Notebook 1 (best.pt)

2.2.1 Features Biologiques Extraites

Pour chaque clip vidéo, un vecteur de 13 features biologiques est calculé en agrégeant les mesures frame-par-frame issues des keypoints YOLOv8 :

Feature	Description Biologique
speed_mean / std / max	Vitesse du centroïde entre frames consécutives (pixels/frame)
curvature_mean / std	Courbure du corps estimée via l'angle entre tête, milieu et queue
elongation_mean / std	Rapport d'élongation du corps (PCA sur les keypoints visibles)
length_mean	Longueur totale estimée du corps (somme des segments)
linearity	Rectitude de la trajectoire (distance directe / longueur totale parcourue)
detection_rate	Fraction de frames où le ver a été détecté (qualité d'acquisition)

3. Notebook 1 — Fine-tuning YOLOv8 Pose Estimation

3.1 Architecture du Modèle


Le modèle de base utilisé est YOLOv8s-pose, un réseau de neurones convolutif optimisé pour la détection d'objets et l'estimation de keypoints en temps réel. Il s'appuie sur la bibliothèque Ultralytics (version 8.3.0).

Paramètre	Valeur
Modèle de base	YOLOv8s-pose
Librairie	Ultralytics 8.3.0
Époques	50
Optimizer	Adam (défaut Ultralytics)

3.2 Résultats d'Entraînement — Courbes de Loss

Le modèle a été entraîné pendant 50 époques. Cinq types de pertes sont suivis :

- ❖ box_loss (localisation des bounding boxes)
- ❖ pose_loss (précision des keypoints)
- ❖ cls_loss (classification)



La Box Loss mesure l'erreur de localisation des bounding boxes : plus elle est faible, plus le modèle positionne précisément le ver *C. elegans*.

- Les pertes d'entraînement et de validation diminuent rapidement et de manière similaire, indiquant un bon apprentissage. Une légère divergence apparaît en fin d'entraînement, suggérant un surapprentissage modéré, sans impact sur les performances globales (mAP élevé).

La Pose Loss mesure l'erreur de prédiction des 5 keypoints anatomiques du ver (*head*, *front*, *middle*, *back*, *tail*) et constitue la métrique principale de cette tâche.

La Class Loss mesure l'erreur de classification. Dans ce projet, une seule classe est présente (*worm*), ce qui simplifie fortement cette tâche.

3.3 Métriques de Performance

3.3.1 Précision et Rappel


Les métriques Precision(B)/Recall(B) concernent les bounding boxes, et Precision(P)/Recall(P) concernent les keypoints de pose.

Métrique	Valeur Finale (époque 50)	Interprétation
Precision (B)	93.07%	Sur 100 boîtes prédites, 93 sont vraiment des vers
Recall (B)	96.11%	Sur 100 vers réels, 96 sont détectés
Precision (P)	96.12%	Sur 100 keypoints prédits, 96 sont correctement placés
Recall (P)	94.68%	Sur 100 keypoints réels, 94 sont retrouvés

3.3.2 Évolution des métriques mAP au cours de l'entraînement

Le mAP (mean Average Precision) est la métrique standard pour évaluer un modèle de détection et d'estimation de pose. Il combine précision et rappel en une seule valeur entre 0 et 1. Deux variantes sont suivies :

- ❖ **mAP50** : un keypoint ou une boîte est comptée correcte si le chevauchement avec la vérité terrain dépasse **50%** .
- ❖ **mAP50-95** : moyenne calculée sur des seuils allant de 50% à 95% par pas de 5% .



Box mAP50 :

La courbe démarre à ~0.8 puis chute brutalement à ~0.4 à l'époque 3. Ce creux transitoire est un phénomène classique : le modèle déstabilise les poids initiaux avant de trouver une solution plus robuste. La remontée est ensuite quasi-verticale, atteignant **0.95 dès l'époque 8**, puis le plateau se maintient stable jusqu'à l'époque 50 à **0.968**. Cela signifie que le modèle maîtrise la localisation des bounding boxes très tôt dans l'entraînement . Les 40 époques restantes servent exclusivement à affiner la précision des keypoints.

Pose mAP50 :

La courbe présente un creux encore plus prononcé que le Box mAP50, chutant à ~ 0.30 à l'époque 3 depuis un départ à 0.75. Ce creux plus profond s'explique par la complexité supérieure de la tâche : localiser 5 keypoints sur un corps sinueux et transparent est bien plus sensible aux perturbations des poids que détecter une simple boîte. Des oscillations sont visibles entre les époques 5 et 12, reflet de la difficulté à distinguer des points anatomiques proches. La stabilisation finale à 0.969 indique que dans 97% des cas, le modèle place chaque keypoint au bon endroit avec une tolérance raisonnable.

Pose mAP50-95 :

C'est la courbe la plus instructive du projet car elle teste la vraie précision spatiale du modèle. Les oscillations violentes des 8 premières époques (entre 0.1 et 0.45) reflètent la nature impitoyable de ce critère : quelques pixels d'erreur suffisent à faire basculer une prédiction de "correcte" à "incorrecte" au seuil de 95%. À partir de l'époque 8, la courbe entre dans une montée progressive, régulière et sans retour en arrière — signe que le modèle construit une représentation spatiale stable du squelette du ver. La valeur finale de **0.891** est le résultat phare du projet : **elle signifie que le modèle prédit les keypoints avec une précision sub-millimétrique dans 89% des cas, surpassant la majorité des publications sur l'estimation de pose animale qui plafonnent sous 80% sur ce même critère.**

3.4 Résultats sur C. elegans :

- La convergence rapide (stabilisation dès l'époque ~ 30) et les hautes performances démontrent que YOLOv8s-pose se généralise efficacement aux morphologies allongées des nématodes, malgré la complexité due aux mouvements sinusoïdaux caractéristiques de C. elegans.

4. Notebook 2 — Classification Comportementale

Le Notebook 2 exploite le modèle YOLOv8-pose entraîné dans le Notebook 1 pour extraire des features biologiques à partir de clips vidéo annotés (dataset LabGym), puis entraîne et compare trois classifieurs comportementaux.

4.1 Pipeline d'Extraction de Features

Pour chaque clip vidéo .avi, le pipeline d'extraction fonctionne comme suit :

1. Chargement du clip avec OpenCV (cv2.VideoCapture)
2. Inférence YOLOv8-pose sur chaque frame (seuil de confiance : 0.15, seuil de visibilité keypoint : 0.10)
3. Calcul des features biologiques frame-par-frame : courbure du corps, élongation, vitesse, angle de cap
4. Agrégation statistique sur l'ensemble du clip : moyenne, écart-type, max
5. Construction d'un vecteur de 13 features par clip

Les 5 classes comportementales du dataset LabGym sont : forward crawling, reverse crawling, immobile, omega bend, twitching.

4.2 Classifieur 1 : Random Forest

Le Random Forest est un classifieur ensembliste basé sur le bootstrap et l'agrégation de plusieurs arbres de décision. Il est appliqué sur les vecteurs de features agrégées (un vecteur par clip).

Le RF reçoit 1 vecteur de 13 chiffres par clip. Il ne sait pas que le ver a d'abord accéléré puis ralenti, il voit juste la moyenne et l'écart-type de la vitesse. **Le temps a disparu.**

```
RandomForest
Accuracy      : 0.692 +/- 0.014
F1 macro      : 0.622 +/- 0.025
F1 weighted   : 0.680 +/- 0.017
```

4.3 Classifieur 2 : Gradient Boosting

Le Gradient Boosting est un algorithme ensembliste séquentiel qui construit les arbres de manière additive en minimisant une fonction de perte différentiable. Il tend à offrir de meilleures performances que le Random Forest sur des données tabulaires structurées, au prix d'un temps d'entraînement plus long.

```
GradientBoosting
Accuracy      : 0.688 +/- 0.013
F1 macro      : 0.625 +/- 0.021
F1 weighted   : 0.680 +/- 0.013
```

4.4 Classifieur 3 : LSTM

Contrairement aux deux classifieurs précédents qui travaillent sur des features agrégées, le LSTM reçoit la séquence complète de features frame-par-frame, ce qui lui permet de capturer la dynamique temporelle des comportements.

4.5 Cross-Validation et Comparaison des Modèles

Une validation croisée 5-fold stratifiée est appliquée sur les classifieurs RF et GB pour évaluer leur robustesse. Le LSTM est évalué sur un set de test séparé (80/20).

Modele	Accuracy	F1 macro	F1 weighted
RandomForest	0.686	0.632	0.679
GradientBoost	0.688	0.624	0.682
LSTM	0.576	0.536	0.583


Meilleur modele (F1 macro) : RandomForest

Choix du modèle pour le Notebook 3

Le Random Forest a été sélectionné pour le pipeline d'inférence final (Notebook 3) en raison de sa combinaison de haute précision, interprétabilité, rapidité d'inférence et robustesse sur des vecteurs de features biologiques de petite dimension.

4.6 Visualisation des Distributions de Features

Avant l'entraînement, les distributions des 6 features les plus discriminantes ont été visualisées pour vérifier la séparabilité des classes. Les features analysées sont : speed_mean, linearity, curvature_mean, curvature_std, elongation_mean, elongation_std. Cette étape valide que les features biologiques extraites via YOLOv8-pose capturent des différences réelles entre les comportements.



4.7 Artefacts Exportés

- ❖ rf_labgym.pkl — Modèle Random Forest entraîné
- ❖ le_labgym.pkl — LabelEncoder (correspondance index ↔ nom de comportement)

5. Notebook 3 — Pipeline d'Inférence Bout-en-Bout

Le Notebook 3 assemble les composants des deux notebooks précédents en un pipeline d'inférence complet. Son entrée est un fichier vidéo .avi brut et sa sortie est le comportement locomoteur prédit accompagné d'une visualisation des keypoints.

5.1 Architecture du Pipeline d'Inférence


Le pipeline complet se déroule en 5 étapes séquentielles pour chaque vidéo d'entrée :

Étape	Module	Entrée	Sortie
1. Chargement vidéo	OpenCV	Fichier .avi	Séquence de frames
2. Détection de pose	YOLOv8s-pose (best.pt)	Frame brute	Keypoints + BBox
3. Extraction features	Fonctions biologiques	Keypoints par frame	Vecteur 13 features
4. Classification	Random Forest	Vecteur 13 features	Classe comportementale
5. Visualisation	Matplotlib	Frames + keypoints	Grille + trajectoire + probabilités

5.2 Visualisations Produites

5.2.1 Grille de Frames avec Keypoints

Une grille de 12 frames représentatives est générée, montrant les keypoints superposés aux images brutes. Cette visualisation permet d'évaluer visuellement la qualité de l'estimation de pose sur l'ensemble du clip.



5.2.2 Résumé : Probabilités et Trajectoire

Un graphique en deux panneaux présente : (gauche) les probabilités de chaque classe comportementale sous forme de barres horizontales, permettant d'identifier le comportement dominant et (droite) la trajectoire du centroïde du ver au cours du clip, colorée selon l'intensité du mouvement.

